Fundamentação Teórica da Calibração de Metas Preditivas

O Problema da Meta Empírica

O modelo de metas vigente — baseado na média histórica ponderada (`meta_n_med`) — apresentou um atingimento médio de **32.7% em Novembro e 31.4% em Dezembro**, com respectivamente **87 e 96 filiais** na zona de burnout (abaixo de 50% dos dias batendo a meta) e apenas **10 e 9 filiais** na faixa ideal de 60–75%. Menos de um quarto da rede atingia a meta com regularidade.

Esse cenário não é apenas um problema de calibração numérica. De acordo com a **Goal-Setting Theory** de Edwin Locke e Gary Latham (1990), quando uma meta é percebida como inatingível, a motivação do indivíduo cai a zero — frequentemente antes da metade do período. O gerente da loja faz a conta no dia 15, vê que o bônus está perdido, e o esforço despenca junto. O resultado prático é a queda de faturamento nas semanas finais do mês, aumento de turnover e perda crônica de receita.

A Faixa Ideal de Atingimento

Pesquisas consolidadas da Harvard Business School — notadamente os estudos de **Thomas Steenburgh e Michael Ahearne** sobre motivação de forças de vendas — e benchmarks corporativos mapeados pela **SiriusDecisions (Forrester)** convergem para a mesma conclusão: a faixa de **60% a 75% de atingimento** é o ponto de equilíbrio que maximiza simultaneamente o faturamento e o engajamento da equipe.

Abaixo de 50%, a meta deixa de funcionar como alavanca motivacional e passa a operar como fator de desmobilização sistêmica. Acima de 80%, o efeito inverso se instala: o fenômeno do **sandbagging**, amplamente documentado na literatura de gestão de vendas, no qual a equipe atinge o número antes do fim do mês e retém vendas para o período seguinte, garantindo o bônus futuro sem esforço adicional — enquanto a empresa paga o teto da premiação por desempenho mediano.

A Solução Matemática

A abordagem preditiva traduz a incerteza do modelo de machine learning em uma régua probabilística
para a meta, seguindo a fórmula:

$$\text{Meta} = \mu + Z \times \sigma$$

onde μ é a previsão do XGBoost para a filial no período, σ é o desvio padrão dos resíduos do modelo calculado no conjunto de validação (Outubro), e Z é o fator de stretch calibrado

individualmente para cada filial a partir do comportamento observado em Novembro.

O Z não é um parâmetro global fixado arbitrariamente. Para cada uma das 112 filiais, o algoritmo `brentq` encontrou o Z exato que teria entregado 67.5% de atingimento diário em Novembro — o centro da faixa ideal da literatura. A distribuição resultante dos Z-scores (média de −0.31, desvio de 0.36) revela que a meta empírica histórica era sistematicamente superior à capacidade real das filiais: a maioria precisou de um Z negativo para chegar à faixa saudável, o que confirma o diagnóstico de metas cronicamente superestimadas.

O Resultado da Calibração

Aplicando os Z-scores aprendidos em Novembro sobre as predições de Dezembro — sem nenhum
ajuste adicional, em um holdout puro — o modelo entregou:

Métrica	Meta Empírica (Dez)	Meta Preditiva (Dez)
Atingimento médio da rede	31.4%	55.7%
Filiais na zona ideal (60–75%)	9	40
Filiais em risco de burnout (< 50%)	96	29
Filiais batendo a meta (⩾ 50% dos dias)	14.3%	74.1%

A proporção de filiais batendo a meta saltou de **14.3% para 74.1%**, com 40 filiais atingindo a faixa ideal contra apenas 9 no modelo anterior. As filiais em risco de burnout caíram de 96 para 29 — uma redução de 70% no número de lojas operando em regime de desmotivação crônica.

O atingimento médio de 55.7% ainda fica levemente abaixo do centro da faixa ideal (67.5%), o que indica espaço para refinamento adicional do modelo preditivo — especialmente em relação ao comportamento atípico de Dezembro, com feriados e sazonalidade de fim de ano. O mecanismo
de calibração, contudo, demonstrou generalizar com robustez de um mês para o outro sem acesso a nenhum dado futuro.